

Rapport d'Expertise : Architecture Data Mining et Validation Algorithmique

Projet MANTIS

25 décembre 2025

Table des matières

1	Introduction	2
2	1. Ingestion et Préparation des Données	2
2.1	1.1 Source de Données : NASA C-MAPSS	2
2.2	1.2 Calcul de la RUL (Target)	2
3	2. Ingénierie des Fonctionnalités (Feature Engineering)	2
3.1	2.1 Sélection de Caractéristiques (Feature Selection)	2
3.2	2.2 Création de Descripteurs (Feature Extraction)	2
4	3. Modélisation et Détection d'Anomalies	3
4.1	3.1 Algorithme : Isolation Forest (Optimisé)	3
4.2	3.2 Comparaison : Random Forest (Supervisé)	3
5	4. Résultats de Validation	3
6	Conclusion	3

1 1. Introduction et Contexte Scientifique

Ce document présente une analyse approfondie de la chaîne de traitement de données (Data Pipeline) du système MANTIS. Il vise à fournir une justification théorique et technique des choix architecturaux opérés pour la détection précoce de défaillances sur des systèmes complexes (moteurs turbofans), en se basant sur le dataset standard NASA C-MAPSS.

2 2. Caractérisation des Signaux et Prétraitement

2.1 2.1 Analyse Spectrale et Stationnarité

Les données brutes issues des capteurs embarqués (température EGT, pression HPC, vitesse N1/N2) sont des séries temporelles multivariées $X = \{x_t^{(1)}, \dots, x_t^{(p)}\}_{t=1}^T$. Une analyse préliminaire montre que le processus de dégradation n'est pas stationnaire. La moyenne et la variance conditionnelles μ_t et σ_t^2 évoluent avec le temps t (nombre de cycles).

Stratégie de Nettoyage Pour garantir la robustesse des modèles d'apprentissage, un pipeline de nettoyage rigoureux est appliqué :

1. **Filtrage des modes opératoires** : Le dataset FD001 est filtré pour ne conserver que les données issues du régime nominal stable (*cruise condition*), éliminant le besoin de normalisation par condition opératoire complexe nécessaire pour FD002/FD004.
2. **Lissage Exponentiel (EWMA)** : Pour réduire le bruit de mesure gaussien $\epsilon \sim \mathcal{N}(0, \sigma^2)$, un filtre à moyenne mobile exponentielle est appliqué :

$$\hat{x}_t = \alpha x_t + (1 - \alpha)\hat{x}_{t-1}$$

avec $\alpha = 0.1$, permettant de lisser le signal tout en minimisant le déphasage (lag) critique pour la détection temps-réel.

3 3. Ingénierie des Fonctionnalités (Advanced Feature Engineering)

3.1 3.1 Sélection de Variables par Variance (Thresholding)

L'analyse de la variance inter-cycles montre que 7 capteurs (sur 21) possèdent une variance quasi-nulle ($\sigma^2 < \epsilon$) sur l'ensemble de la vie du moteur. Leur inclusion introduirait de la colinéarité et du bruit sans apport d'information (Gain d'Information ≈ 0). **Capteurs rejetés** : s1, s5, s6, s10, s16, s18, s19. **Dimensionnalité réduite** : $\mathbb{R}^{21} \rightarrow \mathbb{R}^{14}$.

3.2 3.2 Extraction de Caractéristiques Temporelles

L'approche choisie repose sur une fenêtre glissante de taille $w = 15$. Pour chaque fenêtre $W_t = [x_{t-w+1}, \dots, x_t]$, nous calculons :

Tendance Centrale (Mean)

$$\mu_{W_t} = \frac{1}{w} \sum_{i=t-w+1}^t x_i$$

Capture l'évolution lente de la dégradation (ex : augmentation progressive de la température EGT due à l'usure).

Volatilité (Standard Deviation)

$$\sigma_{W_t} = \sqrt{\frac{1}{w-1} \sum_{i=t-w+1}^t (x_i - \mu_{W_t})^2}$$

Indicateur critique d'instabilité système. Une augmentation de la volatilité précède souvent la rupture de stationnarité (bifurcation) menant à la panne.

4 4. Architecture de Détection d'Anomalies

4.1 4.1 Justification de l'Isolation Forest (iForest)

Le choix de l'Isolation Forest (Liu et al., 2008) se justifie par plusieurs propriétés théoriques supérieures aux méthodes basées sur la densité (LOF) ou la distance (SVM One-Class) en haute dimension :

1. **Complexité Algorithmique** : $O(n \log n)$ pour l'entraînement et $O(\log n)$ pour l'inférence, garantissant une latence minimale ($< 50\text{ms}$) compatible avec les contraintes temps-réel industrielles.
2. **Hypothèse d'Isolation** : Les anomalies sont "peu nombreuses et différentes". L'algorithme les isole en un nombre réduit de coupures aléatoires dans l'espace des features.

4.2 4.2 Score d'Anomalie

Le score d'anomalie $s(x, n)$ pour une observation x est défini mathématiquement par :

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}}$$

où :

- $h(x)$ est la longueur du chemin dans un arbre d'isolation (profondeur de la feuille).
- $E(h(x))$ est l'espérance de cette longueur sur l'ensemble de la forêt.
- $c(n)$ est le facteur de normalisation (longueur moyenne d'un chemin dans un BST non réussi).

Si $E(h(x)) \rightarrow 0$, alors $s \rightarrow 1$ (Anomalie forte). Si $E(h(x)) \rightarrow n - 1$, alors $s \rightarrow 0$ (Observation normale).

5 5. Validation Expérimentale et Résultats

5.1 5.1 Protocole d'Évaluation

- **Déséquilibre de Classe** : Le ratio Anomalie/Normal est d'environ 1 :6. L'accuracy est donc une métrique biaisée. Nous privilégions le **ROC-AUC** et le couple **Précision/Rappel**.
- **Définition du Label** : Une fenêtre est étiquetée "Anomalie" ($Y = 1$) si $RUL \leq 30$.

5.2 5.2 Résultats Benchmarks

Configuration	Précision	Rappel	F1-Score	AUC
Baseline (Raw Features)	0.62	0.91	0.73	0.964
Optimisé (Feature Selection)	0.75	0.87	0.81	0.969
RF Supervisé (Upper Bound)	0.83	0.84	0.83	0.985

TABLE 1 – Impact de l'optimisation des features sur la performance.

5.3 5.3 Interprétation Expert

L'augmentation significative de la précision (+13%) démontre que la suppression des capteurs bruités a permis de "nettoyer" l'espace de représentation, éloignant les clusters normaux des zones aberrantes. La légère baisse du rappel (91% \rightarrow 87%) est un compromis acceptable pour drastiquement réduire les fausses alarmes, facteur clé d'acceptabilité par les opérateurs humains.

6 6. Conclusion et Perspectives Industrielles

L'approche proposée combine efficacité computationnelle et robustesse statistique. Pour une mise en production, nous recommandons :

- **Drift Detection** : Surveillance de la distribution des scores $s(x)$ pour détecter une dérive du concept normal.
- **Explicabilité** : Utilisation des valeurs SHAP pour expliquer quelles features contribuent au score d'anomalie lors d'une alerte.